


CHƯƠNG 2. KIẾN THỨC NỀN TẢNG

2.1. Hệ thống máy dò CMS HCAL và đặc tính dữ liệu DigiOccupancy

Máy dò Calo Hadron (Hadron Calorimeter - HCAL) là một phân hệ quan trọng thuộc thí nghiệm CMS tại Tổ chức Nghiên cứu Hạt nhân Châu Âu (CERN). Chức năng cốt lõi của phân hệ này là xác định năng lượng của các hạt hadron thông qua quá trình tương tác hạt và tạo vòi hạt (hadronic showering). Về mặt cấu tạo vật lý, HCAL là một hệ thống đa lớp phức hợp, bao gồm các tấm hấp thụ bằng đồng thau (brass) xen kẽ với các lớp chất nhấp nháy nhựa (plastic scintillator) nhạy sáng.



Hình ảnh 3: Sơ đồ tọa độ không gian () và cấu trúc các tầng vật chất (Depth 1-7) bên trong máy dò.

2.1.1. Hệ tọa độ và cấu trúc phân đoạn không gian

Để quản lý dữ liệu hiệu quả, máy dò được phân đoạn chi tiết theo hệ tọa độ ba chiều đặc thù của vật lý năng lượng cao:

- **Chỉ số η (Pseudorapidity):** Biến số biểu thị góc cực của hạt so với trục chùm tia, phản ánh quỹ đạo chuyển động của hạt theo phương dọc.
- **Chỉ số ϕ (Azimuthal angle):** Đại diện cho góc phương vị quanh trục chùm tia, cung cấp thông tin về hướng phát tán của hạt trên mặt phẳng cắt ngang.
- **Chỉ số Depth (Độ sâu):** Đây là thông số phân đoạn theo hướng tâm, đóng vai trò then chốt trong việc ghi lại hồ sơ năng lượng dọc theo chiều dài của vòi hạt khi chúng xuyên qua các lớp vật chất của máy dò.

2.1.2. Đơn vị Lumisection (LS) và Bản đồ DigiOccupancy


Trong quá trình vận hành máy gia tốc, dữ liệu được thu thập và đóng gói theo các đơn vị thời gian cố định gọi là Lumisection (LS), mỗi LS tương ứng với khoảng 23 giây va chạm liên tục. Dữ liệu thô từ các kênh điện tử sau đó được chuẩn hóa thành bản đồ **DigiOccupancy** — một histogram ba chiều biểu thị mật độ va chạm tại từng tế bào (cell) của máy dò. Bản đồ này đóng vai trò là "vân tay" hoạt động của máy dò; bất kỳ sự sai lệch nào so với phân phối chuẩn (như vùng mất tín hiệu hoặc điểm tín hiệu nhiễu cao) đều là chỉ dấu quan trọng cho các sự cố kỹ thuật tiềm tàng.

2.2. Thách thức từ tính phi tĩnh và hiện tượng trôi dạt dữ liệu (Data Drift)

Trong lĩnh vực vật lý năng lượng cao (HEP), dữ liệu thu được mang tính phi tĩnh (non-stationarity) sâu sắc, nghĩa là các đặc tính thống kê của dữ liệu thay đổi liên tục theo thời gian. Sự biến đổi này không chỉ đơn thuần đến từ các lỗi thiết bị mà còn do các yếu tố vận hành nội tại của máy gia tốc:

1. **Sự suy giảm độ rọi (Luminosity Decay):** Trong mỗi chu kỳ nạp chùm hạt (run), mật độ proton giảm dần theo thời gian do các va chạm liên tục xảy ra. Điều này dẫn đến sự sụt giảm tự nhiên của mật độ DigiOccupancy trung bình, tạo ra một sự thay đổi phân phối liên tục trong suốt quá trình vận hành.
2. **Quá trình lão hóa vật chất của máy dò:** Dưới tác động của bức xạ cường độ cao, các lớp chất nhập nhạy nhựa và linh kiện quang học bị suy giảm hiệu suất một cách không thể tránh khỏi, làm thay đổi phản hồi tín hiệu của hệ thống sau mỗi năm vận hành.
3. **Sự nâng cấp thông số vận hành:** Sự chuyển giao giữa các chiến dịch (như từ Run 2 sang Run 3) thường đi kèm với việc thay đổi năng lượng chùm hạt và cường độ va chạm, tạo ra các bước nhảy vọt (abrupt shifts) trong phân phối dữ liệu.

Về mặt toán học, nếu gọi $p_t(x)$ là phân phối xác suất của dữ liệu tại thời điểm t , thì bài toán đặt ra là $p_t(x) \neq p_{t+1}(x)$. Một mô hình học máy tĩnh huấn luyện trên dữ liệu quá khứ $p_{t-n}(x)$ sẽ nhanh chóng gặp hiện tượng "lỗi thời kỹ thuật" và mất khả năng tổng quát hóa trên dữ liệu hiện tại.



Hình ảnh 4: So sánh bản đồ mật độ và chạm 3D giữa trạng thái vận hành lỗi (2018) và trạng thái ổn định (2022)

2.3. Khung lý thuyết về Học tập liên tục (Continual Machine Learning)

Học tập liên tục (CML) là một lĩnh vực của trí tuệ nhân tạo nghiên cứu việc tối ưu hóa mô hình trên một chuỗi các tập dữ liệu $\{D_t\}_{t=1}^T$ quan sát được theo trình tự thời gian. Mục tiêu trọng tâm là cho phép mô hình tích lũy tri thức mới mà không làm suy giảm khả năng xử lý các nhiệm vụ cũ.

2.3.1. Nghịch lý Plasticity-Stability (Tính dẻo và Tính ổn định)

Đây là thách thức cốt lõi trong CML. Một hệ thống học tập hiệu quả cần đạt được sự cân bằng tinh tế giữa:

- **Tính dẻo (Plasticity):** Khả năng thay đổi trọng số mạng để thích nghi nhanh chóng với các đặc trưng mới từ dòng dữ liệu hiện tại.
- **Tính ổn định (Stability):** Khả năng bảo tồn các cấu trúc tri thức quan trọng đã học được trong quá khứ, đặc biệt là nhận diện các dạng dị thường hiếm gặp nhưng quan trọng.

2.3.2. Đánh giá các chiến lược CML hiện hữu

Các phương pháp truyền thống như điều chuẩn (Regularization - phạt các thay đổi trọng số quan trọng) hay phát lại trải nghiệm (Experience Replay - lưu trữ mẫu cũ) thường bộc lộ những hạn

chế về chi phí lưu trữ và độ trễ tính toán khi triển khai trong môi trường thời gian thực của CMS. Do đó, bài báo này lựa chọn phương pháp **Ensemble (Tập hợp mô hình)** — một chiến lược phân tán năng lực học tập trên nhiều chuyên gia độc lập, cho phép tách biệt rõ rệt quá trình học dữ liệu mới và bảo tồn dữ liệu cũ.

2.4. Phương pháp luận phát hiện dị thường qua Bộ tự mã hóa (Autoencoders)

Phương pháp phát hiện bất thường trong nghiên cứu này dựa trên nguyên lý của mạng **Masked Autoencoder (MAE)**. Đây là một kỹ thuật học không giám sát mạnh mẽ, hoạt động dựa trên logic tái cấu trúc thông tin.

- **Cơ chế che khuất (Masking):** Trong quá trình huấn luyện, một phần dữ liệu DigiOccupancy bị che khuất ngẫu nhiên. Mô hình Transformer (ViT) phải học cách suy luận và tái tạo lại phần dữ liệu bị thiếu dựa trên ngữ cảnh không gian xung quanh.
- **Sai số tái cấu trúc (Reconstruction Error):** Một mô hình được huấn luyện tốt trên dữ liệu bình thường sẽ tái tạo lại các mẫu không dị thường với độ chính xác cao. Ngược lại, khi đối mặt với các dị thường vật lý (như kênh chết hoặc nhiễu nóng), mô hình sẽ gặp khó khăn trong việc tái tạo, dẫn đến sai số tái cấu trúc tăng vọt.
- **Các chỉ số thống kê Z-score và Gap-score:** Để chuyển đổi sai số tái cấu trúc thành quyết định phân loại, nghiên cứu áp dụng các chỉ số thống kê nhằm đo lường độ lệch. Đặc biệt, phương pháp **Gap-score** được giới thiệu để xác định dị thường dựa trên khoảng cách giữa các giá trị sai số lớn nhất, giúp tăng cường độ nhạy bén của hệ thống ngay cả khi mô hình đã bị suy giảm hiệu năng do trôi dạt dữ liệu.

Sự tích hợp giữa kiến trúc Transformer (vốn mạnh về quan hệ không gian xa) và cơ chế Autoencoder tạo nên một "bộ lọc" thông minh, có khả năng nhận diện những sai lệch tinh vi nhất bên trong máy dò Calo Hadron.

CHƯƠNG 3. PHÂN TÍCH NỘI DUNG BÀI BÁO (DEPTHVIT)

3.1. Chủ đề và Mục tiêu của Bài báo

3.1.1. Chủ đề nghiên cứu

Chủ đề trung tâm của bài báo tập trung vào việc phát triển một hệ thống giám sát tự trị có khả năng **Học tập liên tục (Continual Learning - CML)** để đảm bảo chất lượng dữ liệu trong các thí nghiệm vật lý năng lượng cao (HEP). Nghiên cứu này kết hợp giữa các tiến bộ trong kiến trúc mạng nơ-ron thị giác (Vision Transformers) và các chiến lược thích nghi đa mô hình (Ensemble) để đối phó với môi trường thực nghiệm biến động không ngừng tại CERN. Thay vì tiếp cận theo hướng xây dựng các mô hình tĩnh, bài báo đặt trọng tâm vào việc giải quyết bài toán "dữ liệu không tĩnh" (non-stationarity) và hiện tượng trôi dạt phân phối dữ liệu vốn là thách thức lớn đối với AI trong khoa học cơ bản

3.1.2. Mục tiêu cốt lõi

Mục tiêu của nghiên cứu được phân tách rõ ràng qua các khía cạnh sau:

- **Tối ưu hóa kiến trúc mô hình (DepthViT):** Thiết kế một kiến trúc Masked Autoencoder (MAE) đặc thù mang tên DepthViT, có khả năng tận dụng cấu trúc phân đoạn theo chiều sâu của máy dò HCAL để trích xuất đặc trưng vật lý một cách chính xác nhất.
- **Giải quyết bài toán "Quên lãng thảm họa":** Xây dựng một khung làm việc dựa trên Ensemble (tập hợp chuyên gia) nhằm duy trì sự cân bằng giữa tính dẻo (học kiến thức mới từ các đợt chạy máy gia tốc hiện tại) và tính ổn định (giữ lại khả năng nhận diện các dị thường hiếm gặp đã biết trong quá khứ).
- **Nâng cao hiệu suất giám sát (DQM):** Đảm bảo hệ thống đạt độ chính xác (Precision) và khả năng thu hồi (Recall) trên 99% ngay cả dưới các kịch bản trôi dạt dữ liệu cực đoan nhất, chẳng hạn như sự chuyển giao giữa các giai đoạn vận hành Run 2 và Run 3 của CMS.
- **Tối ưu hóa tài nguyên tính toán:** Giảm thiểu số lượng tham số mô hình (xuống còn khoảng 300.000 tham số) để cho phép triển khai đồng thời nhiều mô hình chuyên gia mà không làm tăng độ trễ của hệ thống kích hoạt (trigger system) thời gian thực.
- **Tính ứng dụng thực tiễn:** Xây dựng một giải pháp có khả năng vận hành bền bỉ trong suốt vòng đời dài hạn của máy dò, đặt nền móng cho các hệ thống giám sát thông minh tại giai đoạn High-Luminosity LHC (HL-LHC) trong tương lai.


Tổng quát lại, mục tiêu cuối cùng của bài báo không chỉ dừng lại ở việc cải tiến một thuật toán học máy, mà là thiết lập một **mô hình vận hành (MLOps)** mới cho vật lý thực nghiệm, nơi AI và thiết bị đo lường cùng tiến hóa để bảo vệ tính toàn vẹn của các khám phá khoa học

3.2. Các Đóng góp Kỹ thuật chính

3.2.1. Kiến trúc Depth-wise Convolutional Patching

Trong các mô hình thị giác máy tính truyền thống, bước đầu tiên là chia hình ảnh thành các mảnh (patches) bằng cách sử dụng phép cuộn tổng hợp qua tất cả các kênh màu (RGB). Tuy nhiên, dữ liệu HCAL có đặc thù là các lớp độ sâu (depth) không có sự đối xứng mức độ pixel do sự phát triển không đồng đều của vòi hạt hadron.

Đóng góp kỹ thuật tại đây là việc áp dụng phép cuộn theo chiều sâu (**depth-wise convolution**). Thay vì tổng hợp thông tin xuyên suốt các kênh ngay lập tức, mỗi lớp độ sâu được gán một tập hợp bộ lọc riêng biệt (k). Điều này cho phép mô hình trích xuất các đặc trưng không gian-vật lý đặc thù cho từng lớp máy dò trước khi đưa vào cơ chế chú ý, giúp bảo toàn tính toàn vẹn của dữ liệu vật lý.



Hình ảnh 5: So sánh cơ chế trích xuất mảnh dữ liệu (Patching) giữa Vision Transformer truyền thống và DepthViT.

3.2.2. Cơ chế Chú ý Xuyên Độ sâu (Cross-depth Attention) và Tối ưu hóa Tham số

Đây là đóng góp quan trọng nhất về mặt cấu trúc mạng. Nhóm tác giả đã tái cấu trúc cơ chế chú ý để tập trung vào mối quan hệ giữa 7 lớp độ sâu của máy dò HCAL thay vì mối quan hệ giữa các vùng không gian xa.


Công thức điểm số chú ý (S):

$$S_{lmcd} = \sum_{d=1}^{d_k} \frac{Q_{lcd} K_{lmd}}{\sqrt{d_k}}$$

Giải thích chi tiết:

- Q, K (Query và Key): Đại diện cho các đặc trưng của patch đã được nhúng.
- Chỉ số c, d: Đại diện cho các kênh (độ sâu).
- $\sqrt{d_k}$: Yếu tố tỷ lệ để ổn định gradient.

Sự thay đổi này chuyển đổi độ phức tạp tính toán từ $O(L^2D)$ (ViT chuẩn) sang $O(LC^2D)$. Vì số lượng lớp độ sâu $C=7$ rất nhỏ so với số lượng patch không gian L , DepthViT chỉ tiêu tốn khoảng **300.000 tham số**, giảm 100 lần so với kiến trúc ViT-B/16 (86 triệu tham số).



Hình ảnh 6: Minh họa sự khác biệt giữa cơ chế chú ý theo chuỗi patch và cơ chế chú ý xuyên lớp độ sâu (Cross-depth)

3.2.3. Khung Ensemble đa cấp cho Học tập liên tục

Để đối phó với hiện tượng "Quên đi thảm họa", nghiên cứu đóng góp một khung làm việc dựa trên tập hợp chuyên gia (Ensemble). Hệ thống không cố gắng huấn luyện lại một mô hình duy nhất mà kết hợp kết quả từ nhiều "chuyên gia" DepthViT được huấn luyện trên các dòng dữ liệu khác nhau.

- **Sub-ensemble chuyên biệt:** Mỗi nhóm gồm hai mô hình song song: một sử dụng *Max Scaling* (nhạy với kênh chết) và một dùng *Quantile Scaling* (nhạy với kênh nóng).
- **Logic kết hợp:** Sử dụng phép toán logic **OR**. Nếu bất kỳ chuyên gia nào trong tập hợp gắn nhãn dị thường, hệ thống sẽ phát cảnh báo ngay lập tức. Phương pháp này giúp tách biệt "tính dẻo" (học từ run mới) khỏi "tính ổn định" (giữ kiến thức cũ).

3.2.4. Phương pháp xác định dị thường bằng Z-score và Gap-score

Thay vì chỉ dựa vào sai số tái cấu trúc (reconstruction error) thô, nghiên cứu đóng góp các công cụ thống kê thích nghi:

Công thức Z-score thích nghi:

$$Z = \frac{|pred_{err} - T * \mu_{err}|}{\sqrt{T} * \sigma_{err}}$$

Giải thích chi tiết:

- **T**: Cửa sổ thời gian (thường là 5 lumisection).
- **μ_{err}, σ_{err}** : Các giá trị trung bình và độ lệch chuẩn của sai số, được cập nhật định kỳ từ luồng dữ liệu sạch gần nhất để đối phó với sự trôi dạt dữ liệu (data drift).

Cơ chế Gap-score:

Nghiên cứu giới thiệu ngưỡng dựa trên khoảng cách giữa các giá trị Z-score lớn nhất:

$$Gap = Z_1 - Z_2 > G_0$$


(với $G_0 = 0.3$). Kỹ thuật này cho phép phát hiện dị thường ngay cả khi mô hình bị suy giảm hiệu năng do sự thay đổi của môi trường vận hành, vì các dị thường vật lý thường tạo ra sự đứt gãy rõ rệt hơn so với sự biến động tự nhiên của nền dữ liệu.

3.3. Phân tích Kiến trúc và Phương pháp luận

3.3.1. Triết lý thiết kế: Tối ưu hóa dựa trên đặc tính vật lý của máy dò

Kiến trúc **DepthViT** được xây dựng dựa trên một triết lý thiết kế cốt lõi: mô hình hóa phải tuân thủ nghiêm ngặt cấu trúc vật lý của thiết bị đo. Trong khi các kiến trúc Vision Transformer (ViT) truyền thống xử lý các kênh dữ liệu (như RGB) một cách đồng nhất thông qua các phép cuộn tổng hợp, DepthViT nhận diện rằng mỗi lớp độ sâu (*depth*) trong máy dò HCAL mang những đặc trưng shower vật lý riêng biệt.

Sự giao thoa này dẫn đến việc thay thế các lớp *Patching* tiêu chuẩn bằng **Depth-wise Convolutional Patching**. Phương pháp này đảm bảo rằng các đặc trưng không gian-vật lý tại mỗi lớp máy dò được trích xuất độc lập, ngăn chặn việc nhiễu thông tin giữa các tầng vật liệu khác nhau trước khi đưa vào cơ chế chú ý. Đây là nền tảng quan trọng giúp mô hình hiểu được cách năng lượng của hạt hadron lan tỏa theo phương dọc khi xuyên qua máy dò.



Hình ảnh 7: Sơ đồ luồng xử lý dữ liệu tổng quát của kiến trúc DepthViT Variational Autoencoder.

3.3.2. Phương pháp luận về Hệ thống Chuyên gia (Ensemble-based CML)

Trọng tâm phương pháp luận của bài báo là giải quyết nghịch lý **Plasticity-Stability** (Tính dẻo và Tính ổn định) thông qua một cấu trúc mạng linh hoạt thay vì một mô hình đơn khối.


1. Phân tách nhiệm vụ thông qua Sub-ensembles

Hệ thống không chỉ học một cách chung chung mà chia tách luồng dữ liệu thành các đặc tính thống kê khác nhau. Phương pháp nghiên cứu sử dụng các chiến lược chuẩn hóa dữ liệu song song:

- **Max Scaling:** Tập trung vào việc duy trì độ nhạy tối đa với các kênh bị mất tín hiệu (kênh chết hoặc suy giảm).
- **Quantile Scaling:** Tối ưu hóa việc nhận diện các điểm dữ liệu có giá trị ngoại lai cực cao (kênh nóng).

2. Cơ chế tích lũy tri thức không quên lãng

Thay vì cập nhật trọng số trên một mạng nơ-ron duy nhất — hành động thường dẫn đến "Quên lãng thảm họa" — bài báo đề xuất phương pháp luận **tích lũy chuyên gia**. Mỗi khi máy gia tốc bước vào một chu kỳ vận hành mới với các thông số vật lý thay đổi, một chuyên gia DepthViT mới sẽ được huấn luyện và tích hợp vào hệ thống. Cơ chế này cho phép mô hình thích nghi nhanh chóng với dòng dữ liệu hiện tại (tính dẻo) trong khi vẫn bảo tồn nguyên vẹn khả năng phát hiện dị thường từ các điều kiện trong quá khứ (tính ổn định).



Hình ảnh 8: Khung làm việc Ensemble tích hợp các chiến lược Scaling song song và logic hợp nhất quyết định OR.

3.3.3. Quy trình xác định dị thường và Ra quyết định thống kê

Phương pháp nghiên cứu của bài báo thiết lập một quy trình nghiêm ngặt để chuyển đổi sai số tái cấu trúc từ mô hình thành các quyết định vật lý tin cậy thông qua ba giai đoạn:

- **Giai đoạn Tái cấu trúc:** DepthViT dự đoán các phần dữ liệu bị che khuất (*masking*). Sai số giữa giá trị dự đoán và giá trị thực tế phản ánh mức độ "không bình thường" của dữ liệu so với những gì mô hình đã học.
- **Giai đoạn Chuẩn hóa Thống kê (Z-score):** Để loại bỏ các biến động tự nhiên của máy gia tốc, sai số được đưa vào bộ lọc Z-score thích nghi. Việc cập nhật liên tục các tham số μ_{err} và σ_{err} từ luồng dữ liệu sạch giúp hệ thống phân biệt được giữa "sự thay đổi của môi trường" và "lỗi thực sự của thiết bị".
- **Giai đoạn Hợp nhất Quyết định (Logic OR):** Phương pháp luận ưu tiên tính an toàn tối đa cho dữ liệu vật lý. Bằng cách áp dụng phép toán logic **OR** trên toàn bộ tập hợp chuyên gia, hệ thống đảm bảo rằng chỉ cần một chuyên gia phát hiện dấu hiệu bất thường, một cảnh báo sẽ được kích hoạt. Điều này tạo ra một "mạng lưới giám sát" đa tầng, giảm thiểu tối đa tỷ lệ bỏ sót lỗi (False Negatives).

3.3.4. Tối ưu hóa tính thực tiễn và Khả năng mở rộng

Kiến trúc DepthViT thể hiện một tư duy phương pháp luận hướng tới triển khai thực tế. Bằng cách tối ưu cơ chế chú ý theo chiều sâu, mô hình đạt được kích thước cực gọn (300,000 tham số), cho phép nó vận hành thời gian thực ngay trên hạ tầng tính toán hạn chế tại các trạm thực nghiệm của CERN. Đây không chỉ là một cải tiến về mặt thuật toán, mà còn là một giải pháp thiết thực cho lộ trình hiện đại hóa hệ thống DQM hướng tới giai đoạn High-Luminosity LHC (HL-LHC).